

"AI, Empathy & Ethics" (এআই, সহানুভূতি এবং নৈতিকতা)

"AI, Empathy & Ethics"

Lecture 1

১. পরিচিতি (Introduction)

এই লেকচারের মূল বিষয় হলো — AI (Artificial Intelligence) কীভাবে ন্যায্যতা (**Fairness**), সুরক্ষা (**Protection**), এবং সহানুভূতি (**Empathy**) নিয়ে কাজ করে, এবং এর পেছনের নৈতিক (**ethical**) দিকগুলো কী কী।

Learning Outcomes (শেখার লক্ষ্য):

1. AI Fairness (এআই ন্যায্যতা) বোঝা
2. কেন Protection (সুরক্ষা) প্রয়োজনীয় তা জানা
3. Ethical AI Principles (নৈতিক এআই নীতিমালা) চিহ্নিত করা

"FAIRNESS AND PROTECTION"

Learning Outcomes

- Understand AI Fairness
- Know why protection is necessary
- Identify ethical AI principles

২. AI Fairness (এআই ন্যায্যতা) কী?

সংজ্ঞা (Definition):

AI Fairness মানে হলো, AI-কে প্রতিটা মানুষের সাথে সমানভাবে (**equally**) আচরণ করতে হবে, কোনো রকম অন্যায্য পক্ষপাত (**unfair bias**) বা বৈষম্য (**discrimination**) ছাড়াই।

নিয়ম: **GRRADN**

একটা AI সিস্টেমের সিদ্ধান্ত নেওয়া উচিত না নিচের বিষয়গুলোর ভিত্তিতে (যদি না সেটা আইনগত বা নৈতিকভাবে যুক্তিসঙ্গত হয়):

1. **Gender** (লিঙ্গ)
2. **Race** (জাতি/বর্ণ)
3. **Religion** (ধর্ম)
4. **Age** (বয়স)
5. **Disability** (প্রতিবন্ধিতা)
6. **Nationality** (জাতীয়তা)

গুরুত্বপূর্ণ শর্ত: "Unless legally or ethically justified" — মানে, কিছু ক্ষেত্রে এই factor বিবেচনা করা যৌক্তিক হতে পারে (যেমন, বয়স-ভিত্তিক শিশুদের জন্য বিশেষ কন্টেন্ট ফিল্টারিং করা একটা যৌক্তিক ব্যতিক্রম), কিন্তু সাধারণভাবে এগুলো decision-making-এর ভিত্তি হওয়া উচিত না।

উদাহরণ (Example):

- একটা **recruitment AI** (নিয়োগ প্রক্রিয়ার AI) শুধু প্রার্থীর **skill** (দক্ষতা) যাচাই করবে — **gender** বা **religion** না।
- বাস্তব জীবনে, অনেক কোম্পানি resume screening-এর জন্য AI ব্যবহার করে, কিন্তু যদি সেই AI-কে এমন ডাটা দিয়ে ট্রেন করা হয় যেখানে অতীতে বেশিরভাগ পুরুষ নিয়োগ পেয়েছে, তাহলে AI নিজে থেকেই নারী প্রার্থীদের বিরুদ্ধে পক্ষপাত (bias) শিখে ফেলতে পারে — এটাই fairness-এর মূল সমস্যা।

“Why Fairness is Important?”

Without fairness,

- People lose trust
- Wrong decisions occur
- Legal problems arise
- Human rights may be violated

Example

Face recognition systems once showed much lower accuracy for darker skin tones than lighter skin tones.

৩. Fairness কেন গুরুত্বপূর্ণ? (Why Fairness is Important)

Fairness না থাকলে কী কী সমস্যা হয়

1. মানুষ বিশ্বাস হারায় (**People lose trust**) — যদি একবার মানুষ বুঝতে পারে AI সিস্টেম পক্ষপাতমূলক, তাহলে তারা সেই সিস্টেমের উপর আর ভরসা করবে না। উদাহরণ: একটা loan-approval AI যদি নির্দিষ্ট এলাকার মানুষদের বার বার প্রত্যাখ্যান করে, তাহলে সেই ব্যাংকের প্রতি মানুষের আস্থা কমে যায়।
2. ভুল সিদ্ধান্ত হয় (**Wrong decisions occur**) — পক্ষপাতমূলক ডাটা/মডেল ভুল সিদ্ধান্তের দিকে নিয়ে যায়, যা যোগ্য মানুষকেও বঞ্চিত করতে পারে।
3. আইনি সমস্যা তৈরি হয় (**Legal problems arise**) — অনেক দেশে discrimination-বিরোধী আইন আছে (anti-discrimination law), তাই পক্ষপাতমূলক AI ব্যবহার করলে কোম্পানি মামলার সম্মুখীন হতে পারে।
4. মানবাধিকার লঙ্ঘিত হতে পারে (**Human rights may be violated**) — বৈষম্যমূলক আচরণ মৌলিক মানবাধিকারের লঙ্ঘন, যেমন সমান সুযোগ পাওয়ার অধিকার।
5. সামাজিক বৈষম্য আরও বৃদ্ধি পায় — যদি ইতিমধ্যে বৈষম্যের শিকার একটা গোষ্ঠী AI দ্বারাও বৈষম্যের শিকার হয়, তাহলে সমাজে বিদ্যমান বৈষম্য আরও গভীর হয়।
6. কোম্পানির সুনাম নষ্ট হয় (**reputational damage**) — মিডিয়াতে AI bias নিয়ে খবর প্রকাশিত হলে ব্র্যান্ডের ভাবমূর্তি ক্ষতিগ্রস্ত হয়।
7. অর্থনৈতিক সুযোগ থেকে বঞ্চিত হওয়া — যোগ্য প্রার্থী/গ্রাহক শুধু AI-এর পক্ষপাতের কারণে চাকরি, লোন বা সেবা থেকে বঞ্চিত হতে পারে।
8. **Feedback loop** তৈরি হয় (একটা গুরুত্বপূর্ণ **concept**) — যদি একটা biased AI বার বার একটা নির্দিষ্ট গ্রুপকে বাদ দেয়, তাহলে ভবিষ্যতের training data-ও সেই একই bias বহন করবে, ফলে সমস্যা আরও খারাপ হতে থাকে (self-reinforcing bias)।

Real-world Example (স্লাইডে দেওয়া):

- **Face recognition system** — অতীতে দেখা গেছে, হালকা রঙের ত্বকের (lighter skin tone) মানুষের জন্য যতটা নির্ভুলভাবে কাজ করত, গাঢ় রঙের ত্বকের (darker skin tone) মানুষের জন্য এর accuracy অনেক কম ছিল।
 - কারণ: এই সিস্টেমগুলো যেই ডাটাসেট দিয়ে ট্রেন করা হয়েছিল, তাতে গাঢ় রঙের ত্বকের মানুষদের ছবি তুলনামূলক কম ছিল — এটাকে বলে "**training data bias**" বা "**representation bias**"।
-

“Protection in AI”

Protection means safeguarding users from AI-related harm.

Protection includes:

- ✓ Privacy protection
- ✓ Personal data security
- ✓ Human rights
- ✓ Cybersecurity
- ✓ Safe AI decisions

Goal:

AI should help human, not harm them.

5

8. Protection in AI (এআই-তে সুরক্ষা)

সংজ্ঞা:

Protection মানে হলো, AI-জনিত ক্ষতি (AI-related harm) থেকে ব্যবহারকারীদের রক্ষা করা (safeguarding)।

Protection-এর অন্তর্ভুক্ত বিষয়সমূহ:

1. **Privacy protection** (গোপনীয়তার সুরক্ষা) — ব্যবহারকারীর ব্যক্তিগত জীবনের তথ্য গোপন রাখা।
2. **Personal data security** (ব্যক্তিগত তথ্যের নিরাপত্তা) — ইউজারের ডাটা হ্যাক/চুরি না হওয়া নিশ্চিত করা।
3. **Human rights** (মানবাধিকার) — AI যেন মানুষের মৌলিক অধিকার লঙ্ঘন না করে।
4. **Cybersecurity** (সাইবার নিরাপত্তা) — AI সিস্টেম যেন সাইবার আক্রমণ (attack) থেকে সুরক্ষিত থাকে।
5. **Safe AI decisions** (নিরাপদ AI সিদ্ধান্ত) — AI-এর নেওয়া সিদ্ধান্ত যেন কারো ক্ষতি না করে।
6. **Protection against Misinformation & Deepfakes** (ভুল তথ্য ও ডিপফেইক থেকে সুরক্ষা): AI ব্যবহার করে ভুয়া সংবাদ, ডিপফেইক ছবি/ভিডিও বা সমাজে বিভ্রান্তি ছড়ানো প্রতিরোধ করা।
7. **Algorithmic Safety & Bias Protection** (অ্যালগরিদমীয় নিরাপত্তা ও পক্ষপাত থেকে রক্ষা): AI যেন কোনো নির্দিষ্ট জাতি, ধর্ম বা লিঙ্গের প্রতি বৈষম্যমূলক বা ক্ষতিকর সিদ্ধান্ত না নেয়।
8. **Protection of Intellectual Property & Content** (মেধা স্বত্ব ও কনটেন্ট সুরক্ষা): এআই যেন অন্যের কপিরাইটযুক্ত লেখা, শিল্প বা কোড চুরি না করে এবং কনটেন্ট ক্রিয়েটরদের অধিকার রক্ষা করে।
9. **Child & Vulnerable Group Protection** (শিশু ও সংবেদনশীল জনগোষ্ঠীর সুরক্ষা): শিশুদের মানসিক বিকাশ ক্ষুণ্ণ করে বা সংবেদনশীল মানুষদের প্রতারিত করে এমন কনটেন্ট ও অ্যালগরিদম থেকে রক্ষা করা।
10. **System Resilience & Fallback Safety** (সিস্টেমের স্থিতিস্থাপকতা ও জরুরি নিয়ন্ত্রণ): এআই সিস্টেম হঠাৎ অকার্যকর বা হ্যাকড হলে যেন তাৎক্ষণিকভাবে ম্যানুয়াল বা নিরাপদ ব্যাকআপ মোডে সুইচ করা যায়।

মূল লক্ষ্য (Goal):

"AI should help humans, not harm them" — অর্থাৎ, AI মানুষকে সাহায্য করার জন্য, ক্ষতি করার জন্য না।

"Ethical Principles of AI"

Most AI ethics guidelines include

- Fairness
- Transparency
- Accountability
- Privacy
- Safety
- Human Control

These principles ensure trustworthy AI.

৫. Ethical Principles of AI (এআই-এর নৈতিক নীতিমালা) FTAPSHC

বেশিরভাগ AI ethics guideline-এ যে ৬টা মূল নীতি (principle) অন্তর্ভুক্ত থাকে, সেগুলো ডিটেইলে বুঝি (এটা পরীক্ষায় আসার সম্ভাবনা বেশি):

১. Fairness (ন্যায্যতা)

- সংজ্ঞা: AI যেন কোনো ব্যক্তি বা গোষ্ঠীর প্রতি পক্ষপাতমূলক আচরণ না করে।
- সবার জন্য সমান সুযোগ এবং সমান আচরণ নিশ্চিত করা।

২. Transparency (স্বচ্ছতা)

- সংজ্ঞা: AI কীভাবে একটা সিদ্ধান্ত নিচ্ছে, সেটা বোঝা এবং ব্যাখ্যা করা সম্ভব হতে হবে (explainability)।
- Black-box সিস্টেম (যেখানে ভেতরে কী হচ্ছে বোঝা যায় না) নৈতিকভাবে সমস্যাজনক, কারণ কেউ জানে না কেন AI একটা নির্দিষ্ট সিদ্ধান্ত নিয়েছে।

৩. Accountability (জবাবদিহিতা)

- সংজ্ঞা: AI ভুল সিদ্ধান্ত নিলে, কে দায়ী (responsible) তা স্পষ্ট হতে হবে — ডেভেলপার, কোম্পানি, নাকি ব্যবহারকারী?
- Accountability ছাড়া, ক্ষতিগ্রস্ত ব্যক্তি ন্যায়বিচার পাবে না।

8. Privacy (গোপনীয়তা)

- সংজ্ঞা: ব্যবহারকারীর ব্যক্তিগত তথ্য সংগ্রহ, সংরক্ষণ, এবং ব্যবহারের ক্ষেত্রে সতর্কতা অবলম্বন করতে হবে।
- অপ্রয়োজনীয় ডাটা সংগ্রহ না করা, এবং সংগৃহীত ডাটা সুরক্ষিত রাখা।

৫. Safety (নিরাপত্তা)

- সংজ্ঞা: AI সিস্টেম যেন কোনোভাবেই শারীরিক, মানসিক, বা আর্থিক ক্ষতি না করে।
- বিশেষ করে self-driving car, medical AI-এর মতো safety-critical application-এ এটা অত্যন্ত গুরুত্বপূর্ণ (Week 9-এর "Safety-Critical Applications" topic-এর সাথে সরাসরি সম্পর্কিত, যেটা আমরা আগে আলোচনা করেছি)।

৬. Human Control (মানুষের নিয়ন্ত্রণ)

- সংজ্ঞা: AI যতই স্বাধীন (autonomous) হোক না কেন, শেষ পর্যন্ত মানুষের হাতে override/control করার ক্ষমতা থাকতে হবে।
- এটা অনেকটা আগে আলোচনা করা "lack of override features" concept-এর সাথে মিলে যায় (Therac-25 case-এ যেমন override না থাকাটা একটা সমস্যা ছিল)।

মূল কথা: এই ৬টা principle মিলে একটা **"Trustworthy AI"** (বিশ্বস্ত AI) তৈরি করে।

মনে রাখার সহজ **Trick (FTAPSH)** বা সংক্ষেপে: Fairness, Transparency, Accountability, Privacy, Safety, Human Control

"Trustworthy AI" বা বিশ্বাসযোগ্য এআই গঠনের জন্য আপনার উল্লেখ করা ৬টি প্রিন্সিপল (Fairness, Transparency, Accountability, Privacy, Safety, Human Control) অত্যন্ত গুরুত্বপূর্ণ।

এর পাশাপাশি বিভিন্ন বৈশ্বিক ফ্রেমওয়ার্ক (যেমন: UNESCO, EU AI Act, NIST, IEEE) অনুযায়ী আরও বেশ কিছু গুরুত্বপূর্ণ **Key Principles** যুক্ত করা হয়:

- **Inclusivity & Accessibility** (অন্তর্ভুক্তি ও প্রবেশগম্যতা): এআই প্রযুক্তি যেন কোনো নির্দিষ্ট অঞ্চলের বা ভাষাভাষী মানুষের মধ্যে সীমাবদ্ধ না থেকে সব সমাজের, সব ভাষার ও বিশেষ চাহিদাসম্পন্ন (disabled) মানুষের ব্যবহারের উপযোগী হয়।
- **Reliability & Robustness** (নির্ভরযোগ্যতা ও স্থায়িত্ব): এআই সিস্টেমকে সব ধরনের প্রতিকূল পরিস্থিতিতেও নির্ভুল, নির্ভরযোগ্য এবং সাইবার আক্রমণ প্রতিরোধে সক্ষম হতে হবে।
- **Sustainability & Environmental Well-being** (টেকসই উন্নয়ন ও পরিবেশ সচেতনতা): বড় বড় এআই মডেল ট্রেনিংয়ে প্রচুর বিদ্যুৎ ও শক্তি খরচ হয়। এআই প্রযুক্তির ব্যবহার যেন পরিবেশের ক্ষতি না করে এবং কার্বন ফুটপ্রিন্ট কমায়, তা নিশ্চিত করা।
- **Explainability & Interpretability** (ব্যাখ্যাযোগ্যতা): এআই কীভাবে কোনো সিদ্ধান্ত বা উত্তর তৈরি করল, তা যেন সাধারণ মানুষের বোধগম্য ভাষায় ব্যাখ্যা করা যায় (যা Transparency-র সাথে সম্পর্কিত হলেও টেকনিক্যালি আলাদা)।

- **Data Quality & Governance** (ডেটার মান ও শাসন): এআই মডেলে ব্যবহৃত ডেটা যেন মানসম্মত, হালনাগাদ এবং সঠিকভাবে সংরক্ষিত থাকে, যাতে এটি ভুল বা বিভ্রান্তিকর তথ্য তৈরি না করে।
- **Social and Societal Impact** (সামাজিক কল্যাণ ও মানবসেবা): এআই যেন মানুষের কাজের সুযোগ নষ্ট না করে বরং মানুষের জীবনমান উন্নত করতে এবং সমাজের মূল সমস্যাগুলো সমাধানে ইতিবাচক ভূমিকা রাখে।

সংক্ষেপে: আপনার ৬টি মূল প্রিন্সিপলের সাথে **Reliability** (নির্ভরযোগ্যতা), **Inclusivity** (সবাইকে অন্তর্ভুক্ত করা) এবং **Sustainability** (পরিবেশবান্ধব হওয়া) যুক্ত করলে Trustworthy AI-এর ফ্রেমওয়ার্কটি পুরোপুরি পরিপূর্ণ হয়।

“Fairness vs Accuracy”

Sometimes improving fairness may slightly reduce prediction accuracy.

Accuracy	Fairness
Predicts correctly	Treats everyone equally

Example:

Loan Approval AI

- 95% accurate
- but rejects almost every female applicant.
- High accuracy
- Low fairness

7

৬. Fairness vs Accuracy (ন্যায্যতা বনাম নির্ভুলতা) — এটা একটা গুরুত্বপূর্ণ ও interesting trade-off concept

দুটোর মধ্যে পার্থক্য:

বিষয়	Accuracy (নির্ভুলতা)	Fairness (ন্যায্যতা)
সংজ্ঞা	সঠিকভাবে পূর্বাভাস দেওয়া (predicts correctly)	সবার সাথে সমান আচরণ করা (treats everyone equally)
ফোকাস	Overall performance/ফলাফলের সঠিকতা	Group-ভিত্তিক ন্যায্য আচরণ

Aspect	Fairness	Accuracy
1. Primary Objective	Ensures the AI model does not discriminate against specific groups (race, gender, etc.).	Measures how correctly the AI model makes predictions or decisions.
2. Key Focus	Focuses on ethics, social justice, and unbiased outcomes.	Focuses on technical performance and data precision.
3. Measurement Metrics	Measured by Demographic Parity, Equal Opportunity, and Disparate Impact.	Measured by Precision, Recall, F1-Score, and Accuracy Rate.
4. Main Challenge	Identifying and removing historical biases present in the training data.	Avoiding prediction errors caused by overfitting, underfitting, or noise.
5. The Trade-off	Enhancing fairness can sometimes slightly reduce overall system accuracy.	Maximizing accuracy alone can lead to severe bias against minority groups.

উদাহরণ (Loan Approval AI):

- একটা Loan Approval AI-এর accuracy ৯৫% (মানে বেশিরভাগ ক্ষেত্রে সঠিক সিদ্ধান্ত নেয়)।
- কিন্তু এই AI-টা প্রায় সব নারী আবেদনকারীকে (**female applicant**) প্রত্যাখ্যান করে।
- ফলাফল: **High Accuracy**, কিন্তু **Low Fairness** — সংখ্যার হিসেবে সিস্টেমটা ভালো কাজ করছে মনে হয়, কিন্তু বাস্তবে এটা একটা নির্দিষ্ট গ্রুপের প্রতি চরম অন্যায়।

গুরুত্বপূর্ণ Insight (মূল শিক্ষা):

"Sometimes improving fairness may slightly reduce prediction accuracy" — মানে, fairness বাড়াতে গেলে অনেক সময় সামগ্রিক accuracy কিছুটা কমে যেতে পারে। এটাই এই ক্ষেত্রের সবচেয়ে বড় trade-off (একটা বাড়াতে গেলে আরেকটা কিছুটা ছাড় দিতে হতে পারে)।

কেন এমন হয় (ব্যাখ্যা): ধরো, বাস্তব জগতের historical data-তে যদি সত্যিই একটা bias থেকে থাকে (যেমন অতীতে নারীদের কম লোন দেওয়া হয়েছে অর্থনৈতিক বৈষম্যের কারণে), তাহলে সেই data দিয়ে ট্রেন করা AI "সবচেয়ে নির্ভুলভাবে" পুরনো প্যাটার্নটাই পুনরাবৃত্তি করবে। কিন্তু আমরা চাই AI যেন সেই ঐতিহাসিক অন্যায় প্যাটার্ন অনুসরণ না করে — আর সেটা করতে গেলে "raw accuracy"-এর সংজ্ঞা অনুযায়ী কিছুটা ছাড় দিতে হতে পারে।

“Balancing Fairness and Accuracy”

Developers try to balance

✓ High Accuracy

✓ High Fairness

Methods include

➤ Better datasets

➤ Bias detection

➤ Fairness algorithms

➤ Human review

৭. Balancing Fairness and Accuracy

(ন্যায্যতা ও নির্ভুলতার ভারসাম্য বজায় রাখা)

Developer-রা কী চেষ্টা করেন:

- **High Accuracy** এবং **High Fairness** — দুটোই একসাথে অর্জন করার চেষ্টা করা (perfect balance)।

এই ভারসাম্য অর্জনের পদ্ধতি (**Methods**) — বিস্তারিত:

1. **Better datasets** (উন্নত ডাটাসেট)
 - ব্যাখ্যা: ট্রেনিং ডাটাসেটে সব গ্রুপের (gender, race, age ইত্যাদি) সমান ও পর্যাপ্ত প্রতিনিধিত্ব (representation) নিশ্চিত করা। যদি ডাটাসেটে কোনো একটা গ্রুপের স্যাম্পল কম থাকে, তাহলে সেই গ্রুপের জন্য AI ভালো কাজ করবে না।

এক লাইনে সারসংক্ষেপ:

- ভুল ডাটার কারণে আউটলায়ার হলে → সেটা **Noise** (যা মুছে ফেলতে হয়)।
- সত্যিকারের অস্বাভাবিক ঘটনার কারণে আউটলায়ার হলে → সেটা **Inconsistent Pattern / Anomaly** (যা বিশ্লেষণ করতে হয়)।
- **DOB Problem indicates Inconsistent**

2. **Bias detection** (পক্ষপাত সনাক্তকরণ)
 - ব্যাখ্যা: AI মডেল তৈরি করার পর, বিভিন্ন গ্রুপের জন্য এর performance আলাদা আলাদাভাবে যাচাই করা — যাতে বোঝা যায় কোনো নির্দিষ্ট গ্রুপের প্রতি পক্ষপাত আছে কিনা। এটার জন্য statistical test এবং fairness metric ব্যবহার করা হয়।
3. **Fairness algorithms** (ন্যায্যতা অ্যালগরিদম)

- ব্যাখ্যা: বিশেষভাবে ডিজাইন করা algorithm যা model training-এর সময় fairness constraint যোগ করে — যেমন, নিশ্চিত করা যে প্রতিটা গ্রুপের জন্য approval rate কাছাকাছি থাকে।
4. **Human review** (মানুষের পর্যালোচনা)
- ব্যাখ্যা: শুধু AI-এর সিদ্ধান্তের উপর সম্পূর্ণ নির্ভর না করে, একজন মানুষ (বিশেষ করে গুরুত্বপূর্ণ/সংবেদনশীল সিদ্ধান্তের ক্ষেত্রে) সেই সিদ্ধান্ত পর্যালোচনা করে চূড়ান্ত অনুমোদন দেওয়া। এটা "Human Control" নীতির সাথেও সরাসরি সম্পর্কিত।

High Accuracy এবং **High Fairness**-এর মধ্যে ভারসাম্য অর্জনের জন্য আরও কিছু গুরুত্বপূর্ণ পদ্ধতি (Methods) নিচে যোগ করা হলো:

5. **Regularization & Constraint Techniques** (নিয়ন্ত্রণ ও অনগ্রসরতা রোধ ব্যবস্থা)

- ব্যাখ্যা: মডেল ট্রেনিংয়ের সময় লস ফাংশনে (Loss function) একটি "Fairness penalty" যুক্ত করা হয়। এর ফলে অ্যালগরিদমটি কেবল সঠিক উত্তরের (Accuracy) পেছনে না ছুটে, বৈষম্যজনক সিদ্ধান্ত নিলে নিজেই নিজেকে পেনাল্টি বা শাস্তি দেয়—যা দুটো বিষয়ের মধ্যে স্বয়ংক্রিয় ভারসাম্য আনে।

6. **Explainable AI / XAI** (ব্যাখ্যাযোগ্য এআই প্রযুক্তি)

- ব্যাখ্যা: এআই কীভাবে নির্দিষ্ট কোনো সিদ্ধান্তে পৌঁছাল তা এক্সপ্লেনেবিলিটি টুলস (যেমন: SHAP, LIME) ব্যবহার করে পর্যবেক্ষণ করা। এর মাধ্যমে ঠিক কোন ফিচারটির (Feature) জন্য মডেলটিতে পক্ষপাত তৈরি হচ্ছে বা অ্যাকুরেসি কমছে তা চিহ্নিত করা সহজ হয়।

7. **Data Augmentation & Synthetic Data Generation** (কৃত্রিম ডেটা তৈরি)

- ব্যাখ্যা: অনগ্রসর বা সংখ্যালঘু গ্রুপগুলোর আসল ডেটা কম থাকলে, এআই টেকনিক ব্যবহার করে তাদের জন্য নির্ভুল "কৃত্রিম ডেটা" (Synthetic Data) তৈরি করা হয়। এতে কোনো বাস্তব মানুষের গোপনীয়তা নষ্ট না করেই ডেটাসেটের ভারসাম্য ও বৈচিত্র্য বাড়ানো যায়।

8. **Post-processing Adjustments** (ফলাফল বা প্রেডিকশন পরবর্তী সমন্বয়)

- ব্যাখ্যা: মডেল ট্রেনিং শেষ হওয়ার পর, প্রাপ্ত প্রেডিকশনের ওপর নির্দিষ্ট থ্রেশহোল্ড (Threshold) বা মানদণ্ড সামঞ্জস্য করা। এর মাধ্যমে প্রতিটি আলাদা গ্রুপের জন্য সিদ্ধান্ত গ্রহণের মার্জিন আলাদা করে সেট করা হয়, যাতে ফলাফলটি সবার জন্য সমানভাবে ফেয়ার হয়।

9. **Continuous Monitoring & Feedback Loops** (নিয়মিত নজরদারি ও ফিডব্যাক)

- ব্যাখ্যা: মডেলটি রিয়েল-ওয়ার্ল্ডে ডেপ্লয় বা চালু করার পরও ক্রমাগত এর পারফরম্যান্স পর্যবেক্ষণ করা। সময়ের সাথে সাথে বাস্তব জগতের ডেটা পরিবর্তনের কারণে তৈরি হওয়া নতুন কোনো bias বা accuracy loss দ্রুত ধরে তা রি-ট্রেনিংয়ের ব্যবস্থা করা।
-

“Perception & Empathy”

Perception means

How AI understands information from

✓ Images

✓ Speech

✓ Text

✓ Sensors

Examples

➤ Face Recognition

➤ Voice Assistant

➤ Self-driving Cars

9

৮. Perception & Empathy (উপলব্ধি এবং সহানুভূতি)

Perception (উপলব্ধি) কী?

সংজ্ঞা: Perception মানে হলো, AI কীভাবে বিভিন্ন উৎস থেকে তথ্য বোঝে/গ্রহণ করে (understand information)। উৎসগুলো হলো:

1. **Images** (ছবি) — visual data প্রসেস করে বোঝা।
2. **Speech** (কথা/বক্তব্য) — অডিও থেকে কথা শনাক্ত করা।
3. **Text** (লেখা) — লিখিত ভাষা বোঝা (Natural Language Processing)।
4. **Sensors** (সেন্সর) — বিভিন্ন যন্ত্র থেকে আসা signal (তাপমাত্রা, দূরত্ব, গতি ইত্যাদি)।

Perception-এর বাস্তব উদাহরণ:

1. **Face Recognition** (মুখ শনাক্তকরণ) — ছবি থেকে ব্যক্তি চেনা।
 2. **Voice Assistant** (কণ্ঠস্বর সহকারী) — যেমন Siri, Alexa, Google Assistant — কথা শুনে বোঝা এবং সাদা দেওয়া।
 3. **Self-driving Cars** (স্বয়ংক্রিয় গাড়ি) — বিভিন্ন sensor (camera, lidar, radar) থেকে তথ্য নিয়ে রাস্তা, বাধা, ট্রাফিক সিগন্যাল বোঝা।
-

“What is Empathy?”

Empathy refers to

- Understanding another person's emotions.
- Humans naturally have empathy.
- AI cannot truly feel emotions.
- It only predicts emotions using data.

Example

A chatbot says:

"I am sorry you are feeling sad."

It recognizes emotional words, but it does not actually feel sadness.

10

৯. What is Empathy? (সহানুভূতি কী?) — সংজ্ঞা:

Empathy (সহানুভূতি) মানে হলো — অন্য একজন মানুষের অনুভূতি বোঝা (**understanding another person's emotions**)।

মানুষ বনাম **AI**-এর মধ্যে মূল পার্থক্য (

1. মানুষের স্বাভাবিকভাবেই **empathy** আছে (**Humans naturally have empathy**) — মানুষ সত্যিকার অর্থে অন্যের কষ্ট/আনন্দ অনুভব করতে পারে, কারণ তাদের নিজস্ব emotional experience এবং consciousness আছে।
2. **AI** প্রকৃতপক্ষে অনুভূতি অনুভব করতে পারে না (**AI cannot truly feel emotions**) — AI-এর কোনো consciousness বা subjective experience নেই।
3. **AI** শুধু **data** ব্যবহার করে অনুভূতির পূর্বাভাস দেয় (**It only predicts emotions using data**) — AI মূলত **pattern recognition** করে। এটা তোমার লেখা শব্দ, কণ্ঠস্বরের টোন, বা মুখের expression বিশ্লেষণ করে বলতে পারে "এই ব্যক্তি সম্ভবত দুঃখিত/খুশি" — কিন্তু এটা নিজে কিছু অনুভব করে না, শুধু ডাটার প্যাটার্ন মিলিয়ে **prediction** করে।

উদাহরণ (**Example**, স্লাইডে দেওয়া):

- একটা chatbot বলে: "**I am sorry you are feeling sad.**" (আমি দুঃখিত যে তুমি মন খারাপ অনুভব করছ)
- এখানে chatbot টা তোমার লেখা টেক্সট থেকে **emotional word** (আবেগঘন শব্দ) চিনতে পেরেছে (যেমন "sad", "upset" ইত্যাদি শব্দ শনাক্ত করে)।

- কিন্তু chatbot সত্যিকার অর্থে দুঃখ অনুভব করছে না — এটা শুধু একটা appropriate response generate করছে prediction-এর ভিত্তিতে।

এই পার্থক্যটা কেন গুরুত্বপূর্ণ (নৈতিক দৃষ্টিকোণ থেকে):

- এটা একটা গুরুত্বপূর্ণ **ethical consideration** — যদি মানুষ ভুল করে ভাবে AI সত্যিই তাদের অনুভূতি বুঝছে/অনুভব করছে (anthropomorphism — মানবিক গুণাবলী আরোপ করা), তাহলে তারা ভুলভাবে AI-এর উপর মানসিক নির্ভরতা তৈরি করে ফেলতে পারে।
- বিশেষ করে mental health chatbot-এর ক্ষেত্রে এটা একটা বড় আলোচনার বিষয় — AI কতটা "সহানুভূতিশীল" আচরণ দেখাতে পারে, কিন্তু সেটা সবসময় স্পষ্ট থাকা উচিত যে এটা একটা simulation/prediction, প্রকৃত অনুভূতি না।

১০. Summary / Revision Part (সব কিছু এক নজরে)

- **AI Fairness:** AI-কে সবার সাথে সমান আচরণ করতে হবে — gender, race, religion, age, disability, nationality-এর ভিত্তিতে বৈষম্য করা যাবে না (যদি না legally/ethically justified হয়)।
- **Fairness** না থাকলে কী হয়: মানুষ বিশ্বাস হারায়, ভুল সিদ্ধান্ত হয়, আইনি সমস্যা হয়, মানবাধিকার লঙ্ঘিত হয়। উদাহরণ: face recognition-এ darker skin tone-এর জন্য কম accuracy।
- **Protection:** Privacy, personal data security, human rights, cybersecurity, safe AI decisions — লক্ষ্য: AI মানুষের সাহায্য করবে, ক্ষতি না।
- ৬টা **Ethical Principle:** Fairness, Transparency, Accountability, Privacy, Safety, Human Control — এগুলো মিলে "Trustworthy AI" তৈরি করে।
- **Fairness vs Accuracy:** দুটো ভিন্ন জিনিস — উচ্চ accuracy থাকলেও low fairness থাকতে পারে (Loan approval AI উদাহরণ: 95% accurate কিন্তু female applicant প্রত্যাখ্যান)। Fairness বাড়াতে গেলে accuracy কিছুটা কমতে পারে — এটাই মূল trade-off।
- **Balance** করার উপায়: Better dataset, bias detection, fairness algorithm, human review।
- **Perception:** AI কীভাবে image, speech, text, sensor থেকে তথ্য বোঝে — উদাহরণ: face recognition, voice assistant, self-driving car।
- **Empathy:** মানুষের সত্যিকার empathy আছে, কিন্তু AI প্রকৃত অনুভূতি অনুভব করে না — শুধু data থেকে emotion predict করে (pattern recognition-এর মাধ্যমে), সত্যিকার অনুভব করে না। এই পার্থক্যটাই সবচেয়ে গুরুত্বপূর্ণ concept এই স্লাইডে।

এই টপিকে যদি "৫ মার্কের প্রশ্ন" ধরনের কিছু আসে, সবচেয়ে বেশি সম্ভাবনা আছে:

1. **Fairness vs Accuracy trade-off** ব্যাখ্যা করতে বলা
2. ৬টা **Ethical Principle** list এবং ব্যাখ্যা করতে বলা
3. **AI** কেন সত্যিকার **Empathy** অনুভব করতে পারে না — ব্যাখ্যা করতে বলা
4. Fairness না থাকলে কী কী সমস্যা হয় তার list

“AI, Empathy & Ethics- (Discriminators)”

Lecture 2

"AI, Empathy & Ethics – Lecture 2 (Discrimination)"

১. পরিচিতি (এই লেকচারের বিষয়)

এই লেকচার মূলত আগের লেকচারের (Fairness & Protection) ধারাবাহিকতা — এখানে আরও গভীরভাবে দেখানো হচ্ছে **AI Discrimination** (এআই বৈষম্য) আসলে কী, কেন হয়, এবং এটা কীভাবে মোকাবিলা/সমাধান (mitigation) করা যায়।

“What is AI Discrimination?”

AI discrimination happens when AI treats one group unfairly.

Reasons

- Biased data
- Poor algorithms
- Historical inequalities

২. What is AI Discrimination? (এআই বৈষম্য কী?)

সংজ্ঞা:

AI Discrimination (এআই বৈষম্য) ঘটে যখন AI কোনো একটা নির্দিষ্ট গোষ্ঠীর (group) সাথে অন্যায় আচরণ (unfairly treat) করে।

এর কারণ (Reasons) — এই ৩টাই মূল কারণ, খুব গুরুত্বপূর্ণ:

1. **Biased data** (পক্ষপাতদুষ্ট ডাটা)

- ব্যাখ্যা: AI যেই ডাটা দিয়ে ট্রেন হয়, সেই ডাটাতেই যদি ইতিমধ্যে অসামঞ্জস্য/পক্ষপাত (imbalance) থাকে, তাহলে AI সেটাই শিখে ফেলে। যেমন, যদি training data-তে ৯০% ছবি হালকা ত্বকের মানুষের হয়, তাহলে AI গাঢ় ত্বকের মানুষদের জন্য ভালো কাজ করবে না।

2. **Poor algorithms** (দুর্বল অ্যালগরিদম)

- ব্যাখ্যা: কিছু algorithm নিজে থেকেই এমনভাবে ডিজাইন করা হয় যে সেটা fairness বিবেচনা না করে শুধু "overall accuracy" maximize করার চেষ্টা করে — এতে সংখ্যালঘু গোষ্ঠীর (minority group) জন্য ফলাফল খারাপ হতে পারে।

3. **Historical inequalities** (ঐতিহাসিক অসমতা)

- ব্যাখ্যা: সমাজে আগে থেকেই যে বৈষম্য বিদ্যমান ছিল (যেমন, অতীতে নারীদের কম চাকরি দেওয়া হতো), সেই ঐতিহাসিক প্যাটার্ন যখন ডাটাতে প্রতিফলিত হয়, AI সেটাকেই "স্বাভাবিক প্যাটার্ন" হিসেবে শিখে ফেলে এবং ভবিষ্যতেও সেই বৈষম্য চালিয়ে যায়।

Lack of Diversity in AI Development Teams (ডেভেলপার টিমে বৈচিত্র্যের অভাব)

- ব্যাখ্যা: AI যারা তৈরি করছেন (প্রকৌশলী ও গবেষক), সেই দলে যদি সব ধর্ম, বর্ণ বা লিঙ্গের মানুষের সমান প্রতিনিধিত্ব না থাকে, তবে তারা নিজের অজান্তেই মডেলে নিজস্ব চিন্তা ও পক্ষপাতের প্রতিফলন ঘটাতে পারেন। বৈচিত্র্যময় টিম না থাকলে সম্ভাব্য বৈষম্যগুলো চিহ্নিত করাই কঠিন হয়ে পড়ে।

Proxy Variables / Hidden Feature Correlation (প্রক্সি ভ্যারিয়েবল বা প্রচ্ছন্ন বৈশিষ্ট্যের সংযোগ)

- ব্যাখ্যা: অনেক সময় ডাটাসেট থেকে স্পর্শকাতর তথ্য (যেমন: জন্মের বা রেস) বাদ দেওয়া হলেও, অন্য কোনো বাহ্যিক ডাটা (যেমন: পিন কোড, জিপ কোড বা স্কুলের নাম) সেই গোষ্ঠীর পরিচয় প্রকাশ করে ফেলে। অ্যালগরিদম এই প্রক্সি ভ্যারিয়েবলগুলো ব্যবহার করে পরোক্ষভাবে ঠিকই বৈষম্যমূলক সিদ্ধান্ত নিয়ে নেয়।

Feedback Loops and Self-Fulfilling Prophecies (ফিডব্যাক লুপ বা বৈষম্যের পুনরাবৃত্তি)

- ব্যাখ্যা: AI যদি কোনো গোষ্ঠীর ব্যাপারে একবার ভুল বৈষম্যমূলক সিদ্ধান্ত নেয়, পরবর্তীতে সেই ভুলের ভিত্তিতেই নতুন ডাটা তৈরি হয়। যেমন: কোনো এলাকাকে AI ভুলবশত "High Crime Area" স্ক্যাগ করলে সেখানে পুলিশি পাহারা বাড়ে, ফলে সেখানে বেশি গ্রেপ্তার ঘটে এবং এআই-এর সেই ভুল ধারণাটিই বাস্তবে আরও পাকাপোক্ত হয়।

Inadequate Testing and Contextual Blindness (অপর্যাপ্ত পরীক্ষা ও প্রেক্ষাপট না বোঝা)

- ব্যাখ্যা: AI মডেলটি বাস্তবে ছাড়ে (Deploy করার) আগে বিভিন্ন সাংস্কৃতিক, আঞ্চলিক বা সামাজিক প্রেক্ষিত চিন্তা করে পর্যাপ্ত টেস্ট (Subgroup Testing) না করা। একটি নির্দিষ্ট দেশে বা কালচারে যে মডেল নিরপেক্ষ মনে হয়, অন্য সংস্কৃতিতে গিয়ে সেটি তীব্র বৈষম্য তৈরি করতে পারে।

“AI Discrimination Cont’d”

Types

- Gender Bias
- Racial Bias
- Age Bias
- Disability Bias
- Language Bias

Example

An AI translator performs poorly for low-resource languages.

3

৩. Types of AI Discrimination (এআই বৈষম্যের ধরন) — ৫টা প্রধান ধরন:

1. **Gender Bias** (লিঙ্গ-ভিত্তিক পক্ষপাত) — নারী/পুরুষের প্রতি ভিন্ন আচরণ।
2. **Racial Bias** (জাতিগত পক্ষপাত) — বিভিন্ন race/ethnicity-এর প্রতি ভিন্ন আচরণ।
3. **Age Bias** (বয়স-ভিত্তিক পক্ষপাত) — বয়স্ক বা কম বয়সী মানুষের প্রতি ভিন্ন আচরণ।
4. **Disability Bias** (প্রতিবন্ধিতা-ভিত্তিক পক্ষপাত) — শারীরিক/মানসিক প্রতিবন্ধী মানুষদের প্রতি ভিন্ন আচরণ।
5. **Language Bias** (ভাষাগত পক্ষপাত) — কিছু ভাষার প্রতি ভালো performance, অন্য ভাষার প্রতি খারাপ performance।

উদাহরণ (Example — Language Bias):

- একটা **AI translator** (অনুবাদক) যেসব ভাষার জন্য পর্যাপ্ত ডাটা পাওয়া যায় না (**low-resource languages**, যেমন ছোট/স্বল্প-প্রচলিত ভাষা), সেসব ভাষার ক্ষেত্রে খারাপ performance দেখায়।
 - কারণ: ইংরেজি বা চাইনিজ-এর মতো ভাষায় প্রচুর training data পাওয়া যায়, কিন্তু ছোট ভাষাগুলোতে (যেমন কিছু আদিবাসী ভাষা) পর্যাপ্ত ডাটা না থাকায় AI ভালোভাবে শিখতে পারে না।
-

“AI Discrimination Cont’d”

Real-world examples

- Hiring AI
- Rejected female resumes more often.
- Face Recognition
- Higher error rates for darker skin tones.
- Healthcare AI
- Less accurate predictions for minority patients.

8. Real-World Examples of AI Discrimination (বাস্তব জগতের উদাহরণ)

১. Hiring AI (নিয়োগ AI):

- সমস্যা: নারী প্রার্থীদের resume বেশি সংখ্যায় প্রত্যাখ্যান করেছে (rejected female resumes more often)।
- কারণ বিশ্লেষণ: যদি কোম্পানির অতীতের নিয়োগ ডাটাতে বেশিরভাগ পুরুষ কর্মী থাকে (কারণ ওই sector-এ ঐতিহাসিকভাবে পুরুষ প্রাধান্য ছিল), AI সেই প্যাটার্ন শিখে ফেলে এবং মনে করে "পুরুষ প্রার্থী = ভালো candidate", ফলে নারী প্রার্থীদের কম যোগ্য মনে করে বাদ দিতে থাকে।

২. Face Recognition (মুখ শনাক্তকরণ):

- সমস্যা: গাঢ় রঙের স্বকের (darker skin tones) মানুষের জন্য error rate (ভুলের হার) বেশি।
- এটা আগের লেকচারেও উল্লেখ ছিল — training data-তে diversity-র অভাবই এর মূল কারণ।

৩. Healthcare AI (স্বাস্থ্যসেবা AI):

- সমস্যা: সংখ্যালঘু (minority) রোগীদের জন্য কম নির্ভুল prediction (less accurate predictions)।
- কারণ: medical research এবং clinical trial-এর ডাটা ঐতিহাসিকভাবে একটা নির্দিষ্ট জনগোষ্ঠীর (যেমন white/Caucasian population) উপর বেশি করা হয়েছে, তাই AI অন্য জনগোষ্ঠীর শারীরিক বৈশিষ্ট্য/রোগের লক্ষণ ভালোভাবে চিনতে পারে না।

এই তিনটা উদাহরণের মূল সাধারণ শিক্ষা: প্রতিটা ক্ষেত্রেই সমস্যার মূল উৎস একই — **historical/imbalanced training data**, যা AI নিজে থেকেই শিখে নেয় এবং পুনরাবৃত্তি করে।

“Causes of AI Bias”

Biased Training Data



Biased Model



Unfair Decisions



Social Harm

৫. Causes of AI Bias — Flow Diagram (Slide 5)

Diagram-টা এরকম একটা চেইন (**chain**) দেখাচ্ছে (৪টা ধাপ, একটার পর একটা ঘটে):

Biased Training Data (পক্ষপাতদুষ্ট প্রশিক্ষণ ডাটা)



Biased Model (পক্ষপাতদুষ্ট মডেল)



Unfair Decisions (অন্যায় সিদ্ধান্ত)



Social Harm (সামাজিক ক্ষতি)

প্রতিটা ধাপের ব্যাখ্যা (Step-by-step):

ধাপ ১: **Biased Training Data** (পক্ষপাতদুষ্ট প্রশিক্ষণ ডাটা)

- শুরু হয় এখান থেকে। যদি AI-কে যে ডাটা দিয়ে শেখানো (train) হচ্ছে, সেই ডাটার মধ্যেই অসামঞ্জস্য/পক্ষপাত থাকে (যেমন কোনো একটা গ্রুপের প্রতিনিধিত্ব কম, অথবা ঐতিহাসিক বৈষম্য প্রতিকলিত হয়েছে), তাহলে সমস্যার শুরু এখান থেকেই হয়।

ধাপ ২: **Biased Model** (পক্ষপাতদুষ্ট মডেল)

- AI যেহেতু ডাটা থেকে প্যাটার্ন শেখে (**learns patterns**), তাই **biased data** দিয়ে ট্রেন করা হলে মডেলটাও নিজে থেকে **biased** হয়ে যায় — মানে মডেল নিজেই এখন সেই পক্ষপাত ধারণ করে ফেলেছে তার internal logic-এ।

ধাপ ৩: **Unfair Decisions** (অন্যায় সিদ্ধান্ত)

- যেহেতু মডেলটাই এখন **biased**, তাই এটা যখন বাস্তব জীবনে ব্যবহার হয় (যেমন loan approval, resume screening), তখন এটা অন্যায় সিদ্ধান্ত দিতে থাকে — নির্দিষ্ট গোষ্ঠীর প্রতি বার বার বৈষম্যমূলক আচরণ করে।

ধাপ ৪: **Social Harm** (সামাজিক ক্ষতি)

- শেষ পর্যন্ত, এই অন্যায় সিদ্ধান্তগুলো বাস্তব মানুষের জীবনে প্রকৃত ক্ষতি ঘটায় — চাকরি না পাওয়া, লোন না পাওয়া, ভুল চিকিৎসা পাওয়া ইত্যাদি। এটা সামাজিক বৈষম্যকে আরও গভীর করে তোলে।

এই **diagram**-এর মূল শিক্ষা (**Key Takeaway**): এটা একটা **cause-and-effect chain** (কারণ-ফলাফল শৃঙ্খল) — সমস্যাটা শুরু হয় ডাটা থেকে, তাই যদি এই সমস্যা সমাধান করতে হয়, তাহলে সবচেয়ে প্রথম ধাপ (**root cause**) — অর্থাৎ ডাটার মান উন্নত করা থেকেই শুরু করতে হবে। এই কারণেই পরের স্লাইডে "Bias Mitigation"-এর প্রথম ধাপ হিসেবে "Collect balanced data" রাখা হয়েছে।

“Manage Fairness and Non-Discrimination Risks”

Managing AI Fairness Risks

Organizations should:

- Use diverse datasets
- Test for bias
- Monitor AI continuously
- Include human oversight
- Follow ethical guidelines

৬. Managing AI Fairness and Non-Discrimination Risks (ন্যায্যতা ঝুঁকি ব্যবস্থাপনা)

Organization-দের (প্রতিষ্ঠানের) করণীয় — ৫টা মূল পদক্ষেপ:

1. **Use diverse datasets** (বৈচিত্র্যময় ডাটাসেট ব্যবহার করা)
 - সব গোষ্ঠীর (age, gender, race ইত্যাদি) পর্যাপ্ত ও সুশ্রম প্রতিনিধিত্ব নিশ্চিত করা।
 2. **Test for bias** (পক্ষপাতের জন্য পরীক্ষা করা)
 - মডেল তৈরির পরে নিয়মিতভাবে বিভিন্ন গ্রুপের জন্য performance যাচাই করে দেখা কোথাও অসামঞ্জস্য আছে কিনা।
 3. **Monitor AI continuously** (ক্রমাগত AI পর্যবেক্ষণ করা)
 - একবার deploy করেই থেমে থাকলে হবে না — সময়ের সাথে সাথে নতুন ডাটা আসতে থাকলে bias develop হতে পারে, তাই চলমানভাবে monitor করতে হবে।
 4. **Include human oversight** (মানুষের তদারকি অন্তর্ভুক্ত করা)
 - গুরুত্বপূর্ণ সিদ্ধান্তে সবসময় একজন মানুষের চূড়ান্ত পর্যালোচনা/অনুমোদন রাখা।
 5. **Follow ethical guidelines** (নৈতিক নির্দেশিকা মেনে চলা)
 - প্রতিষ্ঠিত AI ethics framework/guideline অনুসরণ করা (যেমন আগের লেকচারে বলা ৬টা principle: fairness, transparency, accountability ইত্যাদি)।
-

“Bias Mitigation Techniques”

Before Training

- Collect balanced data

During Training

- Fairness-aware algorithms

After Training

- Audit predictions
- Explain AI decisions

৭. Bias Mitigation Techniques (পক্ষপাত প্রশমন কৌশল) — গুরুত্বপূর্ণ, তিনটা সময়-পর্যায় (stage) অনুযায়ী ভাগ করা হয়েছে

এটা একটা খুব গুরুত্বপূর্ণ framework — AI development-এর তিনটা ধাপে (stage) bias মোকাবিলা করার জন্য ভিন্ন ভিন্ন কৌশল প্রয়োগ করা হয়:

ধাপ ১: Before Training (প্রশিক্ষণের আগে)

- **Collect balanced data** (সুশ্রম ডাটা সংগ্রহ করা)
- ব্যাখ্যা: মডেল ট্রেন করার আগেই নিশ্চিত করা যে ডাটাসেটে সব গ্রুপের সমান/পর্যাপ্ত প্রতিনিধিত্ব আছে। এটাই সবচেয়ে গুরুত্বপূর্ণ ধাপ, কারণ Slide 5-এর diagram অনুযায়ী সমস্যা শুরুই হয় এখান থেকে।

ধাপ ২: During Training (প্রশিক্ষণের সময়)

- **Fairness-aware algorithms** (ন্যায্যতা-সচেতন অ্যালগরিদম)
- ব্যাখ্যা: এমন বিশেষ algorithm ব্যবহার করা যা training-এর সময়েই fairness constraint বিবেচনায় রাখে — শুধু overall accuracy maximize না করে, প্রতিটা গ্রুপের জন্য ন্যায্য ফলাফল নিশ্চিত করার চেষ্টা করে।

ধাপ ৩: After Training (প্রশিক্ষণের পরে)

- **Audit predictions** (পূর্বাভাস নিরীক্ষা করা)
- ব্যাখ্যা: মডেল তৈরি হওয়ার পরে, এর দেওয়া output/prediction গুলো বিভিন্ন গ্রুপ অনুযায়ী ভাগ করে বিশ্লেষণ করে দেখা কোথাও পক্ষপাত আছে কিনা।
- **Explain AI decisions** (AI সিদ্ধান্তের ব্যাখ্যা দেওয়া)
- ব্যাখ্যা: AI কেন একটা নির্দিষ্ট সিদ্ধান্ত নিয়েছে তা বোঝার মতো (explainable) করা — এটা আগের লেকচারের "Transparency" নীতির সাথে সরাসরি সম্পর্কিত।

মূল শিক্ষা: Bias মোকাবিলা করা একটা **one-time** কাজ না, বরং এটা AI development-এর পুরো জীবনচক্র জুড়ে (**before** → **during** → **after**) চলমান একটা প্রক্রিয়া।

ধাপ ১: Before Training (প্রশিক্ষণের আগে — Pre-processing)

- **Collect balanced data** (সুসম ডাটা সংগ্রহ করা): সব গ্রুপের পর্যাপ্ত প্রতিনিধিত্ব নিশ্চিত করা।
- **Sensitive Attribute Removal / Debiasing** (স্পর্শকাতর তথ্য বাদ দেওয়া বা ফিল্টার করা):
 - ব্যাখ্যা: ট্রেনিং ডাটাসেট থেকে জেন্ডার, বর্ণ বা ধর্মের মতো সরাসরি বৈষম্য তৈরি করতে পারে এমন ভ্যারিয়েবলগুলোকে বাদ দেওয়া অথবা সেগুলোকে এমনভাবে ট্রান্সফর্ম করা যাতে মডেল সরাসরি এগুলোকে দেখে সিদ্ধান্ত নিতে না পারে।
- **Resampling Techniques** (রিস্যাম্পলিং):
 - ব্যাখ্যা: যদি ডাটাসেটে কোনো সংখ্যালঘু গ্রুপের ডাটা কম থাকে, তবে **Oversampling** (তাদের ডাটা বাড়িয়ে দেওয়া) অথবা সংখ্যাগুরু গ্রুপের অতিরিক্ত ডাটা কমানোর জন্য **Undersampling** করা।
- **Data Augmentation** (কৃত্রিম ডাটা যোগ করা):
 - ব্যাখ্যা: কৃত্রিম বা নতুন ডাটা পয়েন্ট তৈরি করে কম প্রতিনিধিত্ব থাকা গ্রুপগুলোর সংখ্যা বাড়ানো, যাতে মডেল সমানভাবে শিখতে পারে।

ধাপ ২: During Training (প্রশিক্ষণের সময় — In-processing)

- **Fairness-aware algorithms** (ন্যায্যতা-সচেতন অ্যালগরিদম): ট্রেনিংয়ের সময় fairness constraint বিবেচনায় রেখে রেজাল্ট দেওয়া।
- **Adversarial Debiasing** (অ্যাডভারসারিয়াল ডিবিয়াসিং):
 - ব্যাখ্যা: দুটি এআই মডেল একসাথে কাজ করে—একটি মূল কাজের প্রেডিকশন দেয়, আর দ্বিতীয় মডেলটি (Adversary) চেষ্টা করে প্রথম মডেলের ফলাফল থেকে মানুষের জেন্ডার বা রেস বের করতে পারে কিনা। প্রথম মডেলটি এমনভাবে নিজেকে শুধরে নেয় যেন দ্বিতীয় মডেলটি ব্যর্থ হয়।
- **Fairness Penalty in Loss Function** (লস ফাংশনে পেনাল্টি যোগ করা):
 - ব্যাখ্যা: মডেল যখনই কোনো বৈষম্যমূলক প্রেডিকশন দেয়, তখন তার Loss Function-এ একটি পেনাল্টি বা শাস্তি যুক্ত করা হয়। ফলে অ্যালগরিদমটি কেবল Accuracy বাড়াতে না গিয়ে ফেয়ারনেস বজায় রাখতে বাধ্য হয়।

ধাপ ৩: After Training (প্রশিক্ষণের পরে — Post-processing)

- **Audit predictions** (পূর্বাভাস নিরীক্ষা করা): আউটপুটগুলো গ্রুপভিত্তিক বিশ্লেষণ করে বৈষম্য ধরা।
- **Explain AI decisions (AI সিদ্ধান্তের ব্যাখ্যা দেওয়া):** Transparency বজায় রাখতে XAI (Explainable AI) ব্যবহার করা।
- **Threshold Adjustment / Decision Calibration** (থ্রেশহোল্ড সামঞ্জস্য করা):
 - ব্যাখ্যা: বিভিন্ন গ্রুপের জন্য সিদ্ধান্ত গ্রহণের কাট-অফ বা সিলেকশন মার্জিন (Threshold) সামঞ্জস্য করা। উদাহরণস্বরূপ: ক্রেডিট কার্ড অ্যাপ্রুভালের ক্ষেত্রে অনগ্রসর গ্রুপের জন্য পয়েন্ট কাট-অফ কিছুটা রিল্যাক্স করা, যাতে ফলাফল সবার জন্য ফেয়ার হয়।
- **Continuous Monitoring & Human-in-the-Loop** (ধারাবাহিক মনিটরিং ও ম্যানুয়াল পর্যবেক্ষণ):
 - ব্যাখ্যা: মডেল রিয়েল-ওয়ার্ল্ডে চলার সময়েও লাইভ আউটপুট নিয়মিত ট্র্যাক করা এবং ক্ল্যাগ হওয়া সংবেদনশীল কেইসগুলো একজন মানুষের (Human Reviewer) মাধ্যমে পুনঃযাচাই করা।

“Ethical Risks”


Common Ethical Risks

- Privacy Risk
- Bias Risk
- Security Risk
- Loss of Human Control
- Job Displacement
- Misinformation
- Deepfakes

৮. Ethical Risks (নৈতিক ঝুঁকি) —


1. **Privacy Risk** (গোপনীয়তা ঝুঁকি) — ব্যক্তিগত তথ্য ফাঁস/অপব্যবহার হওয়ার ঝুঁকি।
2. **Bias Risk** (পক্ষপাত ঝুঁকি) — উপরে আলোচিত discrimination-এর ঝুঁকি।
3. **Security Risk** (নিরাপত্তা ঝুঁকি) — সাইবার আক্রমণ বা সিস্টেম hack হওয়ার ঝুঁকি।
4. **Loss of Human Control** (মানুষের নিয়ন্ত্রণ হারানো) — AI-এর সিদ্ধান্তের উপর মানুষের কর্তৃত্ব কমে যাওয়া (Week 9-এর "lack of override feature" concept-এর সাথে মিল আছে)।
5. **Job Displacement** (চাকরি হারানো) — AI/automation-এর কারণে মানুষের কাজ হারানো।
6. **Misinformation** (ভুল তথ্য) — AI দ্বারা ভুল/বিত্রাস্তিকর তথ্য ছড়ানো।
7. **Deepfakes** (ডিপফেক) — AI দিয়ে তৈরি জাল ছবি/ভিডিও/অডিও, যা বাস্তব বলে মনে হয় কিন্তু আসলে fabricated (কৃত্রিমভাবে তৈরি)।

“Ethical Risk Assessment Process”



৯. Ethical Risk Assessment Process (নৈতিক ঝুঁকি মূল্যায়ন প্রক্রিয়া) — Flow Diagram (Slide 9)

Diagram-টা এরকম (৪টা ধাপের একটা চক্র/cycle):



প্রতিটা ধাপের ব্যাখ্যা:

ধাপ ১: Identify Risk (ঝুঁকি চিহ্নিত করা)

- সবচেয়ে প্রথমে, কোন কোন সম্ভাব্য নৈতিক ঝুঁকি (যেমন উপরে উল্লেখিত ৭টা risk) এই নির্দিষ্ট AI system-এ থাকতে পারে, সেটা খুঁজে বের করা।

ধাপ ২: Evaluate Impact (প্রভাব মূল্যায়ন করা)

- চিহ্নিত ঝুঁকিটা যদি সত্যিই ঘটে, তাহলে এর প্রভাব কতটা মারাত্মক হবে সেটা যাচাই করা — কতজন মানুষ প্রভাবিত হবে, কী ধরনের ক্ষতি হবে (আর্থিক, শারীরিক, মানসিক)।

ধাপ ৩: Reduce Risk (ঝুঁকি কমানো)

- মূল্যায়নের ভিত্তিতে, সেই ঝুঁকি কমানোর জন্য প্রয়োজনীয় পদক্ষেপ নেওয়া (যেমন Bias Mitigation Technique প্রয়োগ করা, security measure যোগ করা)।

ধাপ ৪: Monitor Continuously (ক্রমাগত পর্যবেক্ষণ করা)

- একবার ঝুঁকি কমানোর পরেও কাজ শেষ হয় না — সিস্টেমটা সময়ের সাথে সাথে কীভাবে আচরণ করছে তা চলমানভাবে নজরদারি করতে হয়, কারণ নতুন ডাটা/পরিস্থিতিতে নতুন ঝুঁকি তৈরি হতে পারে।

লক্ষণীয় বিষয়: এই diagram-এর চতুর্থ ধাপ (Monitor Continuously) থেকে আবার প্রথম ধাপে (Identify Risk) ফিরে যাওয়ার একটা implicit cycle আছে — অর্থাৎ, এটা একটা **one-time** প্রক্রিয়া না, বরং চলমান চক্র (continuous cycle)।

১০. Ethical Risks — বাস্তব উদাহরণ (Slide 10)

Example: AI in Hospitals (হাসপাতালে AI)

বিষয়	বিবরণ
Possible Risk (সম্ভাব্য ঝুঁকি)	Wrong diagnosis (ভুল রোগ নির্ণয়)
Possible Solution (সম্ভাব্য সমাধান)	Human doctor verifies AI recommendation before treatment (চিকিৎসার আগে মানব ডাক্তার AI-এর সুপারিশ যাচাই করবেন)

এই উদাহরণের মূল শিক্ষা: AI যতই উন্নত হোক না কেন, **critical**/জীবন-মৃত্যুর সিদ্ধান্তে সবসময় একজন human expert-এর final verification থাকা উচিত — এটাই "Human Control" ও "Human oversight" নীতির বাস্তব প্রয়োগ।

“Ethical Risks Cont’d”

Example: AI in Hospitals

Possible Risk

- Wrong diagnosis

Possible Solution

- Human doctor verifies AI recommendation before treatment.

Best Practices

Responsible AI should be

- ✓ Fair
- ✓ Transparent
- ✓ Explainable
- ✓ Secure
- ✓ Accountable
- ✓ Human-centered

10

Best Practices — Responsible AI-এর ৬টা গুণ (এটা আগের লেকচারের ৬টা Ethical Principle-এর সাথে প্রায় হুবহু মিলে যায়, শুধু ক্রম আলাদা):

Responsible AI হওয়া উচিত:

1. **Fair** (ন্যায্য)
2. **Transparent** (স্বচ্ছ)
3. **Explainable** (ব্যাখ্যাযোগ্য)
4. **Secure** (নিরাপদ)
5. **Accountable** (জবাবদিহিমূলক)
6. **Human-centered** (মানবকেন্দ্রিক)

লক্ষণীয়: এখানে "Explainable" এবং "Human-centered" নতুন শব্দ হিসেবে এসেছে, যা আগের লেকচারের "Transparency" এবং "Human Control"-এর সাথে খুব কাছাকাছি ধারণা — মূলত একই core principle-গুলোকেই একটু ভিন্নভাবে সাজানো হয়েছে।

১১. Summary / Revision Part (সব কিছু এক নজরে)

- **AI Discrimination:** যখন AI কোনো গ্রুপের প্রতি অন্যায় আচরণ করে। কারণ: biased data, poor algorithm, historical inequality।
- **৫টা Type of Bias:** Gender, Racial, Age, Disability, Language।
- **৩টা Real-world Example:** Hiring AI (নারী resume বেশি reject), Face Recognition (গাঢ় ত্বকে বেশি error), Healthcare AI (minority patient-এর জন্য কম accurate)।

- **Causes of Bias — 4-step Chain:** Biased Training Data → Biased Model → Unfair Decisions → Social Harm। (মূল কথা: সমস্যা শুরু হয় ডাটা থেকেই)
 - **Managing Fairness Risk —** ৫টা পদক্ষেপ: Diverse dataset, bias testing, continuous monitoring, human oversight, ethical guideline অনুসরণ।
 - **Bias Mitigation — ৩টা Stage:**
 - Before Training → balanced data collect করা
 - During Training → fairness-aware algorithm
 - After Training → audit predictions + explain AI decisions
 - ৭টা **Ethical Risk:** Privacy, Bias, Security, Loss of Human Control, Job Displacement, Misinformation, Deepfakes।
 - **Ethical Risk Assessment — 4-step Cycle:** Identify Risk → Evaluate Impact → Reduce Risk → Monitor Continuously (এটা একটা চলমান চক্র, one-time প্রক্রিয়া নয়)।
 - **AI in Hospitals** উদাহরণ: Risk = wrong diagnosis, Solution = human doctor verification। এটা প্রমাণ করে critical decision-এ human oversight অপরিহার্য।
 - **Responsible AI**-এর ৬টা গুণ: Fair, Transparent, Explainable, Secure, Accountable, Human-centered।
-

সম্ভাব্য ৫ মার্কের প্রশ্ন যেগুলো আসতে পারে (এবং উত্তর কোথায় পাবে):

1. AI Discrimination-এর কারণ ও ধরন ব্যাখ্যা করো → Section ২ ও ৩
2. Causes of Bias-এর 4-step chain diagram ঐকে ব্যাখ্যা করো → Section ৫
3. Bias Mitigation Techniques (৩টা stage) ব্যাখ্যা করো → Section ৭
4. Ethical Risk Assessment Process diagram ঐকে ব্যাখ্যা করো → Section ৯
5. Responsible AI-এর বৈশিষ্ট্য কী কী → Section ১০